



P1 - Ciência de Dados

Disciplina: Ciência de Dados
Professor: Diego Ramos Inácio
Curso: Engenharia de Software
Município: Saquarema - RJ

Período: 5º
Valor da Prova: 7,0 Pontos

Enunciado

ATENÇÃO:

- Só serão considerados arquivos criados durante a realização da prova. Qualquer arquivo cuja criação seja anterior ao início da prova não será considerado.
- A prova deve ser desenvolvida em **Python 3** (Jupyter Notebook ou Google Colab), usando **pandas**, **numpy** e, se necessário, **scipy**.
- Só será aceita a prova enviada pelo próprio executável baixado no AVA.
- As únicas abas permitidas no acesso ao AVA durante a prova são **P1** e **Presença**.
- NÃO É PROVA DE CONSULTA**; o uso de material externo não será aceito. A única referência permitida é a **Documentação de Apoio contida nesta prova**.
- Produto a ser entregue:** um único arquivo **.ipynb** (ou **.py**) com todo o código de carga, limpeza, transformação, estatística e probabilidade, e as **respostas descritivas** escritas em células *markdown* ou como comentários (#).

MONITORAMENTO DA PROVA — LEIA COM ATENÇÃO

Esta avaliação é acompanhada por um **monitorador** que registra e avalia tudo o que é feito no computador durante a realização da prova. Serão considerados os seguintes pontos:

- O(a) aluno(a) **só pode utilizar o ambiente Python (Jupyter Notebook ou Google Colab)** para responder à prova. Nenhum outro programa deve ser aberto ou utilizado.
- Não será tolerado** o uso de qualquer material, aplicativo, ferramenta de IA generativa ou site que não seja: (1) a **Documentação de Apoio contida nesta prova** e (2) o **AVA**, restrito às abas **P1** e **Presença**.
- Qualquer **consulta externa** (navegador em outras páginas, mensageiros, arquivos locais, IA, etc.) detectada pelo monitorador implica em **anulação da prova**.

Em Ciência de Dados, antes de qualquer análise ou modelo, é preciso **entender o problema de negócio**, avaliar a **qualidade dos dados** e prepará-los. Dados brutos quase sempre chegam sujos: tipos errados, valores ausentes, duplicatas, categorias escritas de formas diferentes e valores impossíveis. Nesta prova você vai **diagnosticar** uma planilha bruta, **limpar e transformar** os dados com **Python / Pandas**, aplicar **estatística descritiva** e responder perguntas de negócio usando **probabilidade**, considerando a loja online **TechShop**.

O conteúdo cobrado vai **até a Aula 04**: Ciência de Dados & Big Data e ciclo de vida do dado (Aula 01), Python para Ciência de Dados (Aula 02), Estatística Descritiva Aplicada (Aula 03) e Probabilidade Aplicada a Negócios (Aula 04).

Contexto do Negócio — Loja Online TechShop

A **TechShop** vende eletrônicos e itens de informática pela internet. A equipe exportou de uma planilha o histórico recente de pedidos para começar a análise de vendas. O arquivo veio **desorganizado**: mesma informação escrita de jeitos diferentes, números como texto, datas em formatos distintos, linhas repetidas e valores que não fazem sentido. Você foi encarregado(a) de preparar esses dados e extrair os primeiros indicadores.

Registro Bruto da Planilha (dados sujos)

id_pedido	data	cliente	uf	categoria	produto	preco_unitario	quantidade	canal	avaliacao	status
1001	2025-01-05	Ana Beatriz Lima	RJ	Eletrônicos	Fone Bluetooth	199,90	2	App	5	Entregue
1002	06/01/2025	João P. Souza	rj	eletronicos	Carregador USB-C	R\$ 89,90	1	Site	4	entregue
1003	2025-01-07	MARINA ROCHA	SP	Informática	Mouse sem fio	129,90	3	app	3	Entregue
1003	2025-01-07	MARINA ROCHA	SP	Informática	Mouse sem fio	129,90	3	app	3	Entregue
1004	08/01/2025	Carlos Andrade	São Paulo	Informática	Teclado mecânico	349,00	1	Site	5	Entregue
1005	2025-01-09	ana beatriz lima	RJ	Acessórios	Capa de notebook	79,90	2	Loja física		Pendente
1006	2025-01-10	Pedro Henrique	MG	Eletrônicos	Caixa de som	259,90	1	App	4	Entregue
1007	10/01/2025	Juliana Martins	mg	ELETRÔNICOS	Smartband	199,00	-1	Site	2	Cancelado
1008	2025-01-11	Rafael Gomes	RJ	Informática	SSD 480GB	329,90	0	App		Cancelado
1009	12/01/2025	Beatriz Nunes	BA	Acessórios	Suporte para celular	39,90	4	site	5	Entregue
1010	2025-01-12	Tiago Ferreira	Bahia	Acessórios	Cabo HDMI	49,90		App	3	Entregue
1011	13/01/2025	Larissa Dias	RJ	Eletrônicos	Headphone Premium	1.199,90	1	Site	1	Entregue
1012	2025-01-14	GUSTAVO LIMA	pr	informática	Webcam HD	159,90	2	app	4	Entregue
1013	14/01/2025	Camila Souza	PR	Acessórios	Mousepad	29,90	5	Loja Física	5	Entregue
1014	2025-01-15	Anderson Melo	RJ	Eletrônicos	Smart TV 50"	2.499,00	1	Site	4	Entregue
1015	15/01/2025	Fernanda Castro	SP	Informática	Notebook	3.799,90	1	App	5	Pendente

Observação: reconstrua essa tabela no notebook manualmente (com `pandas.DataFrame` a partir de uma lista de dicionários) ou salve-a como `techshop_bruto.csv` e carregue com `pd.read_csv`. O importante é que os dados **entrem sujos** e sejam limpos pelo seu código.

Documentação de Apoio — Exemplo Resolvido (contexto diferente)

Observação: a documentação abaixo resolve, do início ao fim, um problema de *outro domínio* (uma *rede de academias*). O objetivo é mostrar o *raciocínio e a sintaxe* de cada etapa de um trabalho de Ciência de Dados. Ela *não resolve a prova*: as colunas, categorias e perguntas da TechShop são outras. Use este exemplo como *modelo a ser refatorado* para o seu problema.

1. Problema de referência: Rede de Academias "MoveMais"

Registro bruto (exportação suja) dos check-ins de alunos em duas unidades:

id_checkin	data_checkin	aluno	unidade	plano	valor_mensalidade	duracao_min	modalidade	nota_experiencia
5001	2024-03-01	Bruno Alves	Centro	Mensal	R\$ 149,90	55	Musculação	4
5002	02/03/2024	bruno alves	centro	mensal	149,90	60	Musculação	5
5003	2024-03-02	Clara Dias	Zona Sul	Anual	R\$ 1.199,00	-10	Pilates	
5004	03/03/2024	DIEGO MOTA	zona sul	Anual	1.199,00	45	Funcional	3
5004	03/03/2024	DIEGO MOTA	zona sul	Anual	1.199,00	45	Funcional	3

1.1. Diagnóstico, tipos de variáveis e onde isso se encaixa no ciclo de dados

```
# --- PROBLEMAS DE QUALIDADE DE DADOS IDENTIFICADOS -----
# - Duplicata exata: o check-in 5004 aparece duas vezes (linha repetida).
# - Datas em formatos diferentes: "2024-03-01" (ISO) e "02/03/2024" (dd/mm/aaaa)
# -> a coluna está como texto, não como data.
# - Texto inconsistente: "Bruno Alves"/"bruno alves"; "Centro"/"centro";
#   "Zona Sul"/"zona sul"; "Mensal"/"mensal"; "DIEGO MOTA" em caixa alta.
# - Número como texto: valor_mensalidade vem como "R$ 149,90" e "1.199,00"
#   (símbolo de moeda, ponto de milhar e vírgula decimal) -> não é float.
# - Valor impossível: duracao_min = -10 (tempo de treino não pode ser negativo).
# - Valor ausente: nota_experiencia vazia no check-in 5003.
#
# Princípio GIGO (Garbage In, Garbage Out): se a análise rodar sobre esses
# dados sem limpeza, TODOS os indicadores (média de permanência, satisfação
# por unidade, receita) sairão errados. Qualidade da entrada = qualidade da saída.
#
# --- CLASSIFICAÇÃO DAS VARIÁVEIS -----
# id_checkin ..... qualitativa nominal (identificador, não se calcula média)
# data_checkin ..... temporal (data)
# aluno ..... qualitativa nominal
# unidade ..... qualitativa nominal
# plano ..... qualitativa ORDINAL (Mensal < Trimestral < Anual - há ordem)
# valor_mensalidade . quantitativa contínua
# duracao_min ..... quantitativa contínua (pode assumir qualquer valor > 0)
# modalidade ..... qualitativa nominal
# nota_experiencia .. qualitativa ordinal (escala 1 a 5) - tratada como discreta
#
# --- FASE DO CICLO DE VIDA DO DADO / CRISP-DM -----
# Estamos entre a "Compreensão dos Dados" (inspecionar, descobrir problemas)
# e a "Preparação dos Dados" (limpar, padronizar, transformar). É a etapa que
# mais consome tempo em um projeto de Ciência de Dados.
#
# --- PLANO DE LIMPEZA -----
# 1) Remover duplicatas.
# 2) Converter data_checkin para datetime (aceitando os dois formatos).
# 3) Padronizar textos: strip + Title Case + mapa de valores canônicos.
# 4) Converter valor_mensalidade para float (tirar "R$", milhar e trocar "," por ".").
# 5) Tratar valores impossíveis: duracao_min <= 0 vira ausente (NaN).
# 6) Decidir o que fazer com ausentes (imputar pela mediana ou manter NaN).
```

2. Carga e inspeção inicial (Aula 02)

```
import pandas as pd
import numpy as np
```

```
# Reconstruindo a planilha bruta (poderia ser pd.read_csv("movemais_bruto.csv"))
bruto = [
    {"id_checkin":5001,"data_checkin":"2024-03-01","aluno":"Bruno Alves","unidade":"Centro",
     "plano":"Mensal","valor_mensalidade":"R$
149,90","duracao_min":55,"modalidade":"Musculação","nota_experiencia":4},
    {"id_checkin":5002,"data_checkin":"02/03/2024","aluno":"bruno alves","unidade":"centro",

"plano":"mensal","valor_mensalidade":"149,90","duracao_min":60,"modalidade":"Musculação","nota_experiencia":5},
    {"id_checkin":5003,"data_checkin":"2024-03-02","aluno":"Clara Dias","unidade":"Zona Sul",
     "plano":"Anual","valor_mensalidade":"R$
1.199,00","duracao_min":-10,"modalidade":"Pilates","nota_experiencia":np.nan},
    {"id_checkin":5004,"data_checkin":"03/03/2024","aluno":"DIEGO MOTA","unidade":"zona sul",

"plano":"Anual","valor_mensalidade":"1.199,00","duracao_min":45,"modalidade":"Funcional","nota_experiencia":3},
    {"id_checkin":5004,"data_checkin":"03/03/2024","aluno":"DIEGO MOTA","unidade":"zona sul",

"plano":"Anual","valor_mensalidade":"1.199,00","duracao_min":45,"modalidade":"Funcional","nota_experiencia":3},
]
df = pd.DataFrame(bruto)

df.head()          # olhar as primeiras linhas
df.shape           # (linhas, colunas)
df.info()          # tipos e não-nulos
df.dtypes          # tipo de cada coluna
df.isnull().sum()  # ausentes por coluna
df.duplicated().sum() # quantas linhas duplicadas
df.describe(include="all")# resumo geral
```

3. Limpeza e padronização (Aulas 01 e 02)

```
# 3.1 Duplicatas
df = df.drop_duplicates().reset_index(drop=True)

# 3.2 Datas em formatos mistos -> datetime
# Cuidado: misturar "aaaa-mm-dd" com "dd/mm/aaaa" numa chamada só costuma
# gerar erro de interpretação. O mais seguro é converter em dois passos:
d = pd.to_datetime(df["data_checkin"], format="%Y-%m-%d", errors="coerce")
d = d.fillna(pd.to_datetime(df["data_checkin"], format="%d/%m/%Y", errors="coerce"))
df["data_checkin"] = d

# 3.3 Padronização de texto (strip + Title Case)
for col in ["aluno", "unidade", "plano", "modalidade"]:
    df[col] = df[col].str.strip().str.title()

# 3.4 Número como texto -> float
df["valor_mensalidade"] = (
    df["valor_mensalidade"].astype(str)
    .str.replace("R$", "", regex=False)
    .str.replace(".", "", regex=False) # tira ponto de milhar
    .str.replace(",", ".", regex=False) # vírgula decimal -> ponto
    .str.strip()
    .astype(float)
)

# 3.5 Valores impossíveis viram NaN
df.loc[df["duracao_min"] <= 0, "duracao_min"] = np.nan

# 3.6 Ausentes: imputar duracao_min pela MEDIANA (robusta a outliers)
df["duracao_min"] = df["duracao_min"].fillna(df["duracao_min"].median())
print(df.dtypes)
print(df.isnull().sum())
```

4. Transformação / novas colunas (Aula 02)

```
# coluna derivada: mês do check-in e duração em horas
df["mes"] = df["data_checkin"].dt.month
df["duracao_h"] = (df["duracao_min"] / 60).round(2)
```

```
# filtro + agrupamento
anuais = df[df["plano"] == "Anual"]
resumo_unidade = (df.groupby("unidade")
                  .agg(checkins=("id_checkin", "count"),
                      duracao_media=("duracao_min", "mean"),
                      nota_media=("nota_experiencia", "mean"))
                  .round(2)
                  .sort_values("checkins", ascending=False))
print(resumo_unidade)
```

5. Estatística descritiva e interpretação (Aula 03)

```
x = df["duracao_min"]

media = x.mean()
mediana = x.median()
moda = x.mode().iloc[0]
desvio = x.std() # amostral (ddof=1)
cv = desvio / media * 100 # coeficiente de variação (%)

Q1 = x.quantile(0.25)
Q3 = x.quantile(0.75)
IQR = Q3 - Q1
lim_inf = Q1 - 1.5 * IQR
lim_sup = Q3 + 1.5 * IQR
outliers = df[(x < lim_inf) | (x > lim_sup)]

assimetria = x.skew()

print(f"média={media:.1f} mediana={mediana:.1f} moda={moda:.1f}")
print(f"desvio={desvio:.1f} CV={cv:.1f}% IQR={IQR:.1f}")
print(f"limites p/ outlier: [{lim_inf:.1f} ; {lim_sup:.1f}] -> {len(outliers)} outlier(s)")
print(f"assimetria (skew) = {assimetria:.2f}")

# INTERPRETAÇÃO (comentário):
# - Se média > mediana, a distribuição tem ASSIMETRIA POSITIVA (cauda à direita):
# poucos treinos muito longos puxam a média para cima -> a MEDIANA representa
# melhor o "aluno típico".
# - CV alto (> 30%) indica muita variabilidade no tempo de permanência.
# - Pontos fora de [lim_inf ; lim_sup] são candidatos a outlier e devem ser
# investigados (erro de registro? aluno que esqueceu de fazer check-out?).
```

6. Correlação (Aula 03)

```
corr = df[["duracao_min", "nota_experiencia"]].corr(method="pearson")
r = df["duracao_min"].corr(df["nota_experiencia"])
print(corr)
print(f"Pearson r = {r:.2f}")

# INTERPRETAÇÃO:
# - r varia de -1 a +1. |r| perto de 0 -> relação linear fraca/inexistente;
# perto de 1 -> forte relação linear positiva; perto de -1 -> negativa.
# - CORRELAÇÃO NÃO É CAUSALIDADE: mesmo que treinos mais longos apareçam
# junto de notas mais altas, isso não prova que um CAUSA o outro
# (pode haver uma terceira variável, como o tipo de plano).
```

7. Análise de variáveis categóricas (Aula 03)

```
# frequência absoluta e relativa
df["modalidade"].value_counts()
df["modalidade"].value_counts(normalize=True).mul(100).round(1)

# tabela de contingência (cruzamento de duas categóricas)
pd.crosstab(df["unidade"], df["plano"])
pd.crosstab(df["unidade"], df["plano"], normalize="index").mul(100).round(1)
```

```
# Análise de Pareto (regra 80/20): quais modalidades concentram os check-ins
pareto = (df["modalidade"].value_counts()
          .to_frame("qtd")
          .assign(perc=lambda d: d["qtd"] / d["qtd"].sum() * 100,
                  acumulado=lambda d: d["perc"].cumsum().round(1)))

print(pareto)
```

8. Probabilidade aplicada ao negócio (Aula 04)

```
from scipy import stats

# 8.1 Probabilidade FREQUENTISTA (a partir dos dados)
# P(experiência boa) = check-ins com nota >= 4 / total de check-ins com nota
notas = df["nota_experiencia"].dropna()
p_boa = (notas >= 4).mean()
print(f"P(nota >= 4) = {p_boa:.2f}")

# 8.2 Probabilidade CONDICIONAL
# P(nota >= 4 | plano == "Anual") = P(nota>=4 E Anual) / P(Anual)
base = df.dropna(subset=["nota_experiencia"])
p_cond = ((base["nota_experiencia"] >= 4) & (base["plano"] == "Anual")).sum() / (base["plano"] ==
"Anual").sum()
print(f"P(nota >= 4 | Anual) = {p_cond:.2f}")

# 8.3 Distribuição BINOMIAL
# Historicamente 70% dos alunos avaliam a experiência como boa (p = 0.70).
# Em 10 novos check-ins, qual a P(exatamente 8 avaliarem como boa)?
p, n, k = 0.70, 10, 8
print("P(X=8) =", stats.binom.pmf(k, n, p))          # exatamente 8
print("P(X<=8) =", stats.binom.cdf(k, n, p))         # no máximo 8

# 8.4 Distribuição de POISSON
# A recepção da unidade Centro recebe em média 3 check-ins por 10 minutos.
# Qual a P(nenhum check-in nos próximos 10 minutos)?
lam = 3
print("P(X=0) =", stats.poisson.pmf(0, lam))         # = e^(-3) ~ 0.0498
```

Resumo do método: (1) entender o problema, (2) inspecionar e diagnosticar, (3) limpar e padronizar, (4) transformar / criar colunas, (5) descrever com estatística, (6) medir relações, (7) analisar categorias, (8) responder perguntas de negócio com probabilidade. É exatamente essa sequência que você deve **refatorar** para a TechShop.

Questões

Questão 1 (1,5 ponto) — Diagnóstico dos Dados e Enquadramento em Ciência de Dados

Analizando o **Registro Bruto da TechShop**, responda em células *markdown* ou como comentários:

- **a) (0,5)** Liste **todos os problemas de qualidade de dados** que você identifica na planilha (tipos incorretos, valores ausentes, duplicatas, categorias inconsistentes, formatos de data, valores impossíveis). Relacione com o princípio **GIGO**.
- **b) (0,5)** **Classifique cada uma das 11 colunas** quanto ao tipo de variável (qualitativa nominal, qualitativa ordinal, quantitativa discreta, quantitativa contínua ou temporal). Justifique as duas que você considerou mais difíceis.
- **c) (0,5)** Indique em que **fase do ciclo de vida do dado / CRISP-DM** essas tarefas se encontram e escreva o seu **plano de limpeza** (passo a passo), citando a Documentação de Apoio como referência de método.

Escreva as respostas no notebook (markdown ou comentários)

Questão 2 (1,5 ponto) — Carga e Limpeza dos Dados

Refatorando o método da Documentação de Apoio para a TechShop:

- **a) (0,3)** Carregue o Registro Bruto em um `DataFrame` (reconstruindo a lista de dicionários ou lendo um `.csv`) e mostre `info()`, `isnull().sum()` e `duplicated().sum()`.
- **b) (0,8)** **Limpe os dados:** remova a linha duplicada; converta `data` para `datetime`; converta `preco_unitario` para `float` (tratando "R\$ ", ponto de milhar e vírgula decimal); padronize `uf`, `categoria`, `canal` e `status` (ex.: "rj", "São Paulo" e "Bahia" viram siglas padronizadas; "eletronicos"/"ELETRÔNICOS" viram "Eletrônicos"); trate quantidade inválida (valores ≤ 0 ou ausentes).
- **c) (0,4)** Adicione **dois novos pedidos**: um com o seu próprio nome como cliente e outro com `status` igual a "Pendente".

Escreva o código no notebook

Questão 3 (1,0 ponto) — Transformação e Agregação

- **a) (0,3)** Crie a coluna `receita = preco_unitario * quantidade`.
- **b) (0,2)** Filtre apenas os pedidos com `status == "Entregue"`.
- **c) (0,5)** Usando `groupby`, apresente por `categoria` a **receita total** e o **ticket médio** (média de receita), ordenando da maior para a menor receita.

Escreva o código no notebook

Questão 4 (1,5 ponto) — Estatística Descritiva e Interpretação

Considere os pedidos com `status == "Entregue"`:

- **a) (0,4)** Calcule **média, mediana e desvio-padrão** da receita, e a **moda** da `avaliacao` considerando **todos os pedidos** da base.
- **b) (0,4)** Calcule o **IQR** da receita e identifique **outliers** pela regra $[Q1 - 1,5 \cdot IQR ; Q3 + 1,5 \cdot IQR]$. Diga quais produtos são os outliers e se você os removeria ou não (justifique).
- **c) (0,4)** Calcule a **assimetria** da receita e **interprete em texto**: a média está acima ou abaixo da mediana? Para que lado está a cauda? Qual medida representa melhor o "pedido típico"?
- **d) (0,3)** Calcule a **correlação de Pearson** entre `quantidade` e `avaliacao` e interprete o valor, lembrando que **correlação não é causalidade**.

Escreva o código e a interpretação no notebook

Questão 5 (1,5 ponto) — Probabilidade Aplicada a Negócio

Usando os dados já limpos da TechShop:

- **a) (0,4) Probabilidade frequentista:** estime $P(\text{status} == \text{"Cancelado"})$ a partir da base.
- **b) (0,5) Probabilidade condicional:** estime $P(\text{avaliacao} \geq 4 \mid \text{canal} == \text{"App"})$.
- **c) (0,6) Distribuição Binomial:** suponha que a taxa histórica de cancelamento seja $p = 0,15$. Em **10 novos pedidos**, calcule $P(\text{no máximo 1 cancelamento})$ e explique, em uma frase, o que esse número significa para a operação da loja.

Escreva o código e a resposta no notebook

Distribuição: $1,5 + 1,5 + 1,0 + 1,5 + 1,5 = 7,0$ pontos. | Conteúdo: Aulas 01 a 04.